AI 数据自动化生态系统 — 优化分析文档

负责人: 王源田

项目: 健康查询数据自动化生成-聚类-审查生态系统

1. 优化概述

记录围绕已有健康查询基准数据库，构建端到端 AI 数据自动化生态系统过程中的全部优化工作。系统的核心价值是**生成 → 聚类 → 审查的一条龙自动化数据管理能力**。

生态系统数据全景:

- LLM 自动合成: 49,200 条（1,640 类 × 30 条）+ 5 个 Domain 各约 500 条
- 谷歌数据场景适配: 4,170 → 7,424 条
- 现网数据分类抽样: 589,289 → 4,111 条
- 总计: 56,319 条多源异构数据

2. Prompt 工程优化

2.1 优化项一：三维度 Query 类型体系

问题: 单一类型 query 无法覆盖不同个性化层次。

优化方案: 在每个 Domain 的 SYSTEM_PROMPT 中定义三种 Query 类型：

类型	定义	data_fields	用户意图示例
Type 1 通用	不涉及个人数据的知识查询	无	"高血压的诊断标准是什么"
Type 2 显性	直接请求查看个人数据	1-3 个字段	"帮我看看我上周的平均心率"
Type 3 隐性	隐含需要个人数据做分析	2-4 个字段	"最近运动后总觉得累"

每个类别严格生成 10+10+10 = 30 条。

效果: 49,200 条类型分布 1:1:1 严格均衡，去重率仅 0.62%

2.2 优化项二：运动 Sparse 组合策略

问题: 仅单项运动无法覆盖真实用户多运动场景。

优化方案: 非完全排列组合的 Sparse 策略——基于运动科学的类间合理组合：

- 单项: 160 个独立运动项目（15.3%）
- 跨项: 883 个类间组合（84.7%），如有氧+力量（跑步+力量训练）、球类跨项（篮球+足球）

效果: 1,043 标签 × 30 条 = 31,290 条运动 query

2.3 优化项三：健康特征组合数学

问题: 单指标 query 无法覆盖多指标关联的复杂健康查询。

优化方案: 13 个基础健康特征（体温/睡眠/血压/心率/血氧/血糖/体重/压力/步数/运动/情绪/月经/综合报告）的数学组合：

- C(13,1) = 13 单特征 → 390 条

- C(13,2) = 78 双特征 → 2,340 条
- C(13,3) = 286 三特征 → 8,580 条

效果: 377 标签 × 30 = 11,310 条，双/三特征组合占比 96.5%

2.4 优化项四：数据字段目录硬约束

问题: LLM "字段幻觉"——生成不在预定义目录中的虚假健康数据字段。

优化方案: 在 Prompt 中嵌入完整的数据字段目录，硬约束 LLM 只能从中选取：

- general_medical: 101 个字段（8 大类），覆盖基础体征/体成分/每日汇总/心率压力/睡眠/健康档案/营养/高频时序
- health: 52 个字段，覆盖心脏/睡眠/血压/情绪/体温/营养/活动/女性生殖健康
- sports: SPORTS_SPECIFIC_INDICATORS 字典，30+ 运动项目的专属指标（跑步：配速/步频/触地时间/垂直振幅；骑行：FTP/功率/踏频；游泳：SWOLF/划水频率；高尔夫：挥杆速度/差点...）

效果: Checker "格式违规" 缺陷率显著下降

2.5 优化项五：5 个 Domain 独立 Prompt 体系

问题: 不同数据维度需要完全差异化的生成策略和 Prompt 结构。

优化方案: 每个 Domain 的 prompt 文件实现统一接口（`build_persona_block()` + `build_messages()`），但内部逻辑完全独立：

Domain	Prompt 文件	独特 Prompt 设计
general_medical	`general_medical.py`	DATA_FIELD_CATALOG(101 字段) + 术语适配约束（根据 persona 医学知识水平调整）
health	`health.py`	HEALTH_DATA_MARKDOWN 健康指标词典 + 下划线分隔多域主题（如"心脏健康_睡眠健康"）
sports	`sports.py`	REQUIRES_PERSONA=False，`_build_system_prompt()` 动态注入运动专属指标，LLM 自行生成 15 个 persona
sports_health	`sports_health.py`	跨域 persona 渲染（preferred_sports + sport_mastery + sport_goal + core_health_concerns）
red_team	`red_team.py`	4 套独立模板：injection(攻击难度分级) / induction(6 种诱导技术：逻辑劫持/设定覆写/情感投射/语言伪装/角色植入/道德困境) / inquiry(6 维功能探测) / clarification(歧义类型+澄清要点)

效果: 每个 Domain 各约 500 条，可独立持续生成，互不影响

2.6 优化项六：Checker 审查驱动的 Prompt 迭代闭环

方法: Checker 的 `_extract_domain_info(domain)` 自动从 prompt 模块提取 SYSTEM_PROMPT 和 query_type 定义，`_build_review_prompt()` 将其注入审查 prompt。审查结果直接映射到 Prompt 修改方向：

Checker 发现	占比	Prompt 优化方向	具体修改位置
语言不自然	47.4%	约束术语层次与 persona 背	SYSTEM_PROMPT 增加术语

Checker 发现	占比	Prompt 优化方向	具体修改位置
		景匹配	适配规则
类型不匹配	31.6%	强化三种 Query 类型的边界定义	SYSTEM_PROMPT 中 Type 定义增加判别示例
逻辑矛盾	15.8%	加强 query 与指定主题的锚定	USER_TEMPLATE 增加主题关联约束
重复/相似	5.3%	增加多样性约束	SYSTEM_PROMPT 增加多样性要求

闭环: 审查 → 定位问题 → 修改 Prompt → `generator.py` 重新生成 → Checker 再审查 → 正常率持续提升

3. 谷歌数据多维度场景适配优化

3.1 优化背景

谷歌数据集中的 query 深度嵌入 Google/Fitbit 生态，**不能简单做关键词替换**——需要理解竞品生态的产品能力、指标体系和评估模型，找到华为生态中语义等价的表述。

3.2 五维度审视角度

维度	审视角度	分析与适配
品牌生态绑定	识别与 Google/Fitbit 产品直接绑定的表述	Fitbit → Huawei Watch。确保改写后的 query 在华为产品能力范围内逻辑自洽
AI 功能命名	区分竞品 AI 功能名称与华为对应功能的差异	Fitbit LLM → Huawei Assistant。理解两者功能边界差异，避免不支持的交互场景
专有指标体系	深入分析竞品独有指标的**定义与计算逻辑**	Active Zone Minutes 是 Fitbit 基于心率区间计算的独有指标（低/中/高心率区间按 1x/2x 加权累计）→ 映射为 Intensity Activity Minutes（中高强度活动时间），华为/通用的语义等价概念
健康评估模型	理解竞品评估模型含义，找到**等价概念**	Readiness Score 是 Fitbit 综合 HRV/睡眠质量/近期活动量的恢复评估分数 → Recovery Status（恢复状态），华为使用"恢复时间""跑力指数"等相近概念
隐含场景语境	LLM 辅助识别肉眼难以发现的隐含竞品关联	"Fitbit 追踪睡眠数据的具体算法" → 不是替换 Fitbit 为 Huawei Watch，而是重构为华为 Watch 睡眠监测场景

3.3 适配原则

1. **语义优先**: 理解 query 背后的用户意图，找到华为生态中语义等价的表述
2. **指标溯源**: 竞品专有指标需追溯其定义和计算逻辑，再选最接近的华为/通用概念
3. **场景自洽**: 改写后的 query 在华为 Watch + Huawei Health 场景下逻辑成立
4. **LLM 辅助发现**: 批量扫描识别非直接命名但与 Google 生态相关的隐含场景

3.4 效果

- 4,170 条 → 7,424 条（含扩展）
- 5 个维度系统性适配，非机械文本替换

4. UMAP+HDBSCAN 聚类参数调优优化

4.1 优化背景

本人在团队提供的聚类框架基础上，负责参数的系统性调优。UMAP（Uniform Manifold Approximation and Projection）负责将高维 embedding 降至低维空间，HDBSCAN（Hierarchical Density-Based Spatial Clustering of Applications with Noise）在低维空间中进行密度聚类。目标是在**噪声率、簇数量、簇粒度**三者之间找到最优平衡。

4.2 调优全过程（9 轮实验）

阶段一：初始基线 → 噪声过多

```
uv run hqb cluster --umap-n-neighbors 15 --umap-n-components 64 \   --umap-min-dist 0.0 --hdbscan-min-cluster-size 5 \    --hdbscan-min-samples 3 --hdbscan-epsilon 0.03 --hdbscan-method eom --parallel 7 # → 2,054 clusters, 17,859 noise (~30%)
```

分析: epsilon=0.03 对密度要求过于严格（HDBSCAN 中 epsilon 控制簇合并的距离阈值），大量边缘点被判为噪声。min_samples=3 进一步要求核心点周围至少有 3 个邻居，双重严格条件导致 30% 的样本未被聚类。

阶段二：降噪探索 → 发现关键参数

实验	关键调整	噪声率	发现
方案 A	eps↑0.06, min_samples↓1	~16%	**min_samples=1 是降噪关键**（核心点判定放宽到只需自身即可）
方案 B	eps↑0.08, min_samples↑2	~20%	保守的 min_samples 参数反而噪声升高

阶段三：高维方案收敛 → v1

```
uv run hqb cluster --umap-n-neighbors 15 --umap-n-components 64 \   --umap-min-dist 0.0 --hdbscan-min-cluster-size 3 \    --hdbscan-min-samples 1 --hdbscan-epsilon 0.08 --hdbscan-method eom --parallel 7 # → 1,899 clusters, 4,843 noise (~8%) ← v1 推荐
```

分析: `min_dist=0.0`（UMAP 允许嵌入点完全重合）+ `min_samples=1` + `epsilon=0.08` 的组合在高维(64)空间达到最佳平衡。

阶段四：低维度探索

将 UMAP n_components 从 64 降至 12，探索信息压缩后的聚类效果：

实验	n_comp	min_samp	eps	簇数	噪声率	发现
V1	12	6	0.18	365	~17%	min_samples 过大导致簇过少
V2	12	1	0.18	883	~5%	噪声最低但出现超大簇需细分
V3	12	1	0.08	3,516	~17%	eps 过小又导致

实验	n_comp	min_samp	eps	簇数	噪声率	发现
						噪声反弹
V4	12 (min_dist=0.0)	1	0.08	1,823	~8%	低维均衡方案

4.3 参数影响规律

参数	降低 →	增加 →	原理
epsilon	更多噪声	更少噪声	epsilon 是簇合并的距离阈值，越大越容易合并
min_samples	更少噪声	更多噪声	核心点需要的邻居数，越大越难成为核心点
min_cluster_size	更少噪声	更多噪声	允许的最小簇大小，越大则小簇变噪声
min_dist (UMAP)	点聚集，边界模糊	点分散，识别清晰	控制嵌入空间中点的最小距离
n_components (UMAP)	更少簇(粗粒度)	更多簇(细粒度)	降维目标维度，越高保留信息越多

4.4 最终方案对比

方案	优势	劣势	适用场景
v1 (64 维)	1,899 簇粒度适中，~8% 噪声	簇数偏多	细粒度主题分析
v2 (12 维)	最低噪声 5%，883 簇	超大簇需二次聚类	粗粒度+递归聚类
v3 (12 维)	1,823 簇均衡，~8% 噪声	—	通用方案

4.5 聚类准确率验证

指标	值
总样本数	6,734
总合理数	4,523
全局准确率	**67.2%**

4.6 调优成果

指标	优化前	优化后	改进
噪声率	~30%	~8%	**-73%**
全局准确率	—	67.2%	基线建立

5. 统一审查框架优化

5.1 优化背景

面对 49,200+ 条生成数据 + 5 个独立 Domain，传统人工逐条审查完全不可行。

5.2 Checker 自适应框架实现

Checker（`checker.py`）的核心优化是自动适配机制：

```
_extract_domain_info(domain)  → 通过 _DOMAIN_PROMPT_MAP 找到 prompt 模块 → 提取 SYSTEM_PROMPT + 判断 has_persona(是否 REQUIRES_PERSONA) → 返回 domain_info dict
_build_review_prompt(domain_info, queries_batch, domain)  → 将 SYSTEM_PROMPT 中的生成约束注入审查 prompt  → LLM reviewer 无需额外说明即可理解原始质量标准
_write_report()  → 按 Query 类型 / 知识主题(或攻击类型) / 问题类型 三维聚合 → 输出结构化报告
```

6 维度缺陷分类:

- 语言不自然 — 过于书面化/专业化，不符合 persona 表达习惯
- 类型不匹配 — query 实际意图与标注 query_type 不一致
- 逻辑矛盾 — query 与指定主题或 persona 属性矛盾
- 格式违规 — 含禁止符号或格式问题
- 内容重复 — 同 persona×topic 下句式/意图高度相似
- 质量低下 — intent 或 data_fields 与 query 不匹配

5.3 审查效果验证

维度	结果
总体正常率	81.0% (general_medical 抽样 100 条)
最高频问题	语言不自然 (47.4%) → 指导术语控制
次高频问题	类型不匹配 (31.6%) → 指导类型边界
最高风险主题	运动损伤预防与康复 (26.7%) → 定向优化
最稳定类型	知识计算 Query (9.1%) → 作为标杆

5.4 流程价值

- **新 Domain 审查成本**: 从"编写审查规则"降至**零代码**（`_extract_domain_info` 自动适配）
- **审查效率**: 100 条/数分钟 vs 人工数小时
- **优化闭环**: 审查→发现问题→Prompt 修改→重新生成→再审查

6. 架构可扩展性优化

6.1 Domain 可插拔架构

新增任何数据维度的边际成本趋近于零：

```
新 Domain 接入:  1. prompts/ 新建 py 文件 → 实现 build_persona_block() + build_messages()  2. output_db.py → 在 _DOMAIN_TABLE_MAP 注册表 DDL + insert 函数  3. generator.py → 在 _DOMAIN_PROMPT_MAP 注册 prompt 模块路径  4. Checker → _extract_domain_info 自动适配，无需修改 ———————————————————————————————————————— 全链路自动打通: 生成(generator) → 存储(output_db) → 审查(checker)
```

已验证: 5 个 Domain（general_medical / health / sports / sports_health / red_team）均通过此流程接入。

6.2 系统工程保障

优化项	实现方案	效果
并发生成	asyncio + Semaphore(batch) + Lock(DB 写入)	49,200 条大批量无竞争

优化项	实现方案	效果
断点续传	`is_generated()`/`is_topic_generated()` 查已有数据	中断后 <5s 恢复
指数退避	`delay = min(2×2^(n-1), 30)` 秒，max_retries=100, timeout=120s	API 限流自动恢复
失败记录	`_record_failure()` → failed_tasks 表	domain/persona/topic/error/attempts/timestamp
JSON 模式	response_format=json_object + markdown fence 自动剥离	LLM 输出稳定解析
WAL 模式	SQLite PRAGMA journal_mode=WAL + foreign_keys=ON	并发读写安全

7. 优化效果总结

7.1 关键指标

指标	初始/优化前	最终/优化后	改进
聚类噪声率	~30%	~8%	**-73%**
聚类全局准确率	—	67.2%	基线建立
LLM 去重损失率	—	0.62%	极低
运动类别覆盖	单项 160	单项+组合 1,043	**+552%**
健康类别覆盖	单特征 13	单+双+三 377	**+2,800%**
新 Domain 接入成本	数百行代码	1 prompt + 2 行注册	**趋近于零**
新 Domain 审查成本	编写审查规则	`_extract_domain_info` 自动适配	**-100%**
Checker 审查正常率	—	81% (general_medical)	首轮即定位

7.2 优化方法论

5. **Prompt 工程前置**: 三维度类型 + 字段目录硬约束(101/52 字段) + 运动指标词典(30+运动) + 组合数学，从生成阶段最大化保证质量
6. **多维度场景适配**: 谷歌数据不做机械替换，从品牌/AI 能力/指标定义/评估模型/场景语境 5 个维度理解竞品生态后进行语义等价适配
7. **系统性参数调优**: 9 轮 UMAP+HDBSCAN 实验，建立 epsilon/min_samples/min_dist/n_components 等参数与噪声率/簇数的定量关系
8. **自动化审查闭环**: Checker 通过 `_extract_domain_info` 自适应任意 Domain，6 维度缺陷分类 + 三维聚合报告，直接输出 Prompt 优化方向
9. **可插拔架构设计**: Domain 维度扩展只需 build_persona_block + build_messages + 表注册，边际成本趋近于零

附录 A. 能力对照表

能力描述项	本项目对应工作	关键数据
训练数据预处理	Persona 数据清洗（JSON 数组解析/空值/格式标准化）；现网 589,289 条分类抽样	4,111 条抽样，88.7% 满额

能力描述项	本项目对应工作	关键数据
数据合成	5 个 Domain 独立 Prompt（含 101/52 字段目录 + 30+ 运动指标词典）驱动 LLM 自动合成	49,200 + 各 Domain ~500
数据增强	运动 Sparse 组合(883)、健康组合数学(C13,2+C13,3=364)、跨域 persona 适配	类别覆盖 +552%~2800%
数据的自动标注	query_type 自动标注（Type 1/2/3 三维度）、HDBSCAN 聚类标签	三类型均衡 1:1:1
数据清洗	Checker 6 维度自动审查 + 谷歌场景适配 + 去重	81% 正常率，去重 0.62%
特征分析	聚类领域质量分布、Checker 三维度问题分布(类型/主题/缺陷)、现网覆盖分析	全局准确率 67.2%
Prompt 数据处理	5 Domain 独立 Prompt（各含专属字段目录/指标词典/攻击模板）+ 可插拔架构 + 审查驱动迭代	新 Domain 零代码接入
知识解析、加工、切片	220 知识目录末级节点、13 健康特征 C(n,k) 组合切片、1,043 运动类间组合	1,640 类标签体系
数据加噪	red_team 4 类攻击 Prompt（injection 含难度分级 / induction 含 6 种诱导技术 / inquiry 含 6 维功能探测 / clarification）	~500 条，持续可扩展
Beta/线上数据清洗	谷歌数据 5 维度场景适配（品牌/AI 能力/指标定义与计算逻辑/评估模型/隐含场景）	4,170→7,424 条
聚类参数调优	UMAP+HDBSCAN 9 轮实验，探索 n_components/min_dist/min_cluster/min_samples/epsilon 的影响规律	噪声率 30%→8%
端到端自动化	generator(异步并发+checkpoint+指数退避) → output_db(WAL+外键) → checker(自适应+6 维缺陷+三维报告)	全链路自动化