AI 数据自动化生态系统 — 模型性能测试报告

负责人: 王源田

项目: 健康查询数据自动化生成-审查生态系统

1. 测试概述

1.1 系统定位

围绕已有的健康查询基准数据库 HQB，构建了一套**端到端 AI 数据自动化生态系统**，核心能力是：

1. **Prompt 驱动的多 Domain 数据合成**: 5 个独立 Domain，各有专属 Prompt 模板（含字段目录/运动指标词典/攻击模板等），各约 500 条，可持续生成扩展
2. **多源数据清洗与场景适配**: 谷歌数据 5 维度生态改写 + 现网 589,289 条分类抽样
3. **统一质量审查闭环**: Checker 从 Domain Prompt 中自动提取约束注入审查，抽样即定位问题，反馈 Prompt 优化

1.2 数据成果总览

数据来源	数量	特性
LLM 自动合成（3 大板块 + 5 个 Domain）	49,200 + 各 Domain ~500	结构化，三维度类型体系
谷歌数据场景适配	4,170→7,424	5 维度生态改写
现网数据分类抽样	589,289→4,111	真实长尾数据
合计	**56,319** (去重后)	**多源异构**

2. 多 Domain Prompt 生成性能

2.1 Domain 可插拔架构与 Prompt 实现细节

每个 Domain 的 Prompt 文件实现两个核心函数：

- `build_persona_block(persona)` — 将 persona 字典渲染为 LLM 可读的结构化卡片（年龄/性别/BMI/健康关注/运动偏好等）
- `build_messages(persona, catalog_topic)` — 构造 [system_prompt, user_message] 消息对

Domain	Prompt 文件	字段/指标体系	核心 Prompt 设计
general_medical	`general_medical.py`	101 个字段（8 大类：基础体征/体成分/每日汇总/心率压力/睡眠/健康档案/营养/高频时序）	Prompt 要求 LLM 根据 persona 医学知识水平适配术语
health	`health.py`	52 个字段 + HEALTH_DATA_MARKDOWN 健康指标词典	支持下划线分隔的多域组合主题（如"心脏健康_睡眠健康"）
sports	`sports.py`	SPORTS_SPECIFIC_INDICATORS：30+ 运动专属指标词典	REQUIRES_PERSONA=False，LLM 自行生成 15 个多样化内联 persona
sports_health	`sports_health.py`	融合运动 (preferred_sports/mastery/goal)与健康属性	跨域 persona：同时携带运动偏好和健康关注

Domain	Prompt 文件	字段/指标体系	核心 Prompt 设计
red_team	`red_team.py`	4 套独立攻击模板	injection(含难度分级)/induction(6 种诱导技术)/inquiry(6 维功能探测)/clarification(歧义类型)

运动指标词典示例（SPORTS_SPECIFIC_INDICATORS）：

- 跑步类：配速/步频/步幅/触地时间/垂直振幅/左右平衡/跑步分析
- 骑行类：FTP/功率/踏频/坡度分析
- 游泳类：划水频率/SWOLF/泳距
- 高尔夫：挥杆速度/挥杆节奏/推杆数/开球准确率/差点

2.2 批量生成板块性能

板块	类别类型	标签数量	生成规则	Query 总数
知识目录	220 个末级树状知识节点	220	30 条/类（10 通用+10 显性+10 隐性）	6,600
运动	单项(160) + 跨项 Sparse 组合(883)	1,043	30 条/类	31,290
健康	13 基础特征的 C(13,1)+C(13,2)+C(13,3)	377	30 条/类	11,310
合计		**1,640**		**49,200**

去重效果: 49,200 → 48,895（去重率 0.62%），说明三维度类型设计有效避免了语义重叠。

2.3 三维度 Query 类型定义

类型	定义	data_fields 要求	示例意图
Type 1 通用	不涉及个人数据的知识查询	无	"高血压的诊断标准是什么"
Type 2 显性个性化	直接请求查看个人数据	1-3 个字段	"帮我看看我上周的平均心率"
Type 3 隐性个性化	隐含需要个人数据做分析计算	2-4 个字段	"最近运动后总觉得累，是不是训练过度了"

分布均衡度 = 1:1:1（每类别严格 10+10+10）

2.4 生成引擎实现细节

generator.py 的任务编排流程：

```
_load_topics() → _build_task_list() → 按 persona×topic round-robin 排列 ↓
asyncio.Semaphore(batch) 控制并发 ↓ _check_is_generated() → 已存在则跳过（checkpoint） ↓
llm_client.chat_json(messages, temp=0.8) → LLM 调用 ↓ _dispatch_insert() → 路由到对应 Domain
的 insert 函数 ↓ 失败 → _record_failure() → failed_tasks 表
```

重试机制: `delay = min(2 × 2^(retry-1), 30)` 秒，默认最大 100 次重试，API 超时 120s。

3. Checker 自动审查机制与闭环优化

> ***说明**: 本章展示的审查结果为小样本抽样（100 条），目的不在于给出统计意义上的质量结论，而是**验证审查机制本身的有效性**——即 Checker 能否在极少样本下快速定位问题类型、高风险主题，并直接指导 Prompt 迭代优化。这套机制可零代码应用于任意 Domain、任意规模的数据。*

3.1 审查机制的核心设计

Checker（`checker.py`）的工作流：

```
_extract_domain_info(domain)      ← 自动提取 SYSTEM_PROMPT + has_persona          ↓
_load_queries(db, domain, ...)   ← 加载 queries（支持 persona 过滤 + 随机抽样）     ↓
_build_review_prompt(info, batch) ← 将生成约束注入审查 prompt                       ↓
llm_client.chat_json(temp=0.3)  ← 低方差审查    ↓ _write_report()              ← 三维聚合报告
```

6 维度缺陷分类体系：

缺陷维度	检测内容
语言不自然	过于书面化/专业化，不符合 persona 的表达习惯
类型不匹配	query 实际意图与标注的 query_type 不一致
逻辑矛盾	query 内容与指定的知识主题或 persona 属性矛盾
格式违规	含禁止符号（带解释的括号、中英混杂等）
内容重复	同 persona×topic 下出现句式/意图高度相似的 query
质量低下	intent 或 data_fields 与 query 内容不匹配

3.2 机制效率对比

对比项	传统人工审查	Checker 自动审查
审查 100 条耗时	数小时	数分钟
新 Domain 接入	编写专用审查规则	`_extract_domain_info` 自动适配
审查标准一致性	依赖审查人员经验	自动与生成 Prompt 约束同步
报告结构化程度	自由文本	三维度自动聚合（类型/主题/问题）
优化方向指引	模糊	直接映射到 Prompt 具体修改点
可扩展性	人力线性增长	对任意 Domain/任意规模复用

3.3 机制验证：general_medical 抽样审查示例

以下为 general_medical Domain 的**小样本抽样审查示例**（100 条），用于验证审查机制的缺陷发现能力和优化指引能力。

配置：`--domain general_medical --sample 100`，分 4 批审查（batch_size=30），temperature=0.3

总体结果

指标	值
抽样审查数	100 条（从全量中随机抽取）
正常 Query	81 条 (81.0%)
标记有问题	19 条 (19.0%)

机制验证一：按 Query 类型定位问题分布

Query 类型	审查数	问题数	问题率	机制定位结论
专业知识 Query	34	6	17.6%	术语专业度需按 persona 背景控制
用户数据查询 Query	33	9	**27.3%**	**类型标注边界需在 Prompt 中强化**

Query 类型	审查数	问题数	问题率	机制定位结论
知识计算 Query	33	3	**9.1%**	质量最稳定，Prompt 设计可作为标杆

机制验证二：按知识主题定位高风险区域

知识主题	问题率	机制定位结论
运动损伤预防与康复	4/15 (**26.7%**)	**最高风险，需优先优化该主题 Prompt**
有氧训练与心肺功能提升	3/14 (21.4%)	术语专业度偏高
运动营养与能量补给策略	3/15 (20.0%)	部分 query 主题偏移
睡眠与运动恢复的关系	2/12 (16.7%)	可接受
运动心率区间与训练强度管理	2/14 (14.3%)	可接受
体脂管理与运动减脂效率	2/15 (13.3%)	可接受
力量训练原则与肌肉恢复	2/15 (13.3%)	可接受

机制验证三：按问题类型 → 直接映射 Prompt 优化方向

问题类型	数量	占比	Checker → Prompt 优化方向
语言不自然	9	**47.4%**	→ Prompt 增加术语层次控制，与 persona 专业背景匹配
类型不匹配	6	**31.6%**	→ Prompt 强化三种 Query 类型的边界定义与判别示例
逻辑矛盾	3	15.8%	→ Prompt 加强 query 核心意图与指定主题的锚定约束
重复/相似	1	5.3%	→ Prompt 增加多样性约束

3.4 典型问题案例（审查机制发现）

案例 1 — 语言不自然（最高频）:

ID: 163 | persona: 136 | 主题: 运动心率区间与训练强度管理 Query: "在运动生理学中，如何根据最大摄氧量百分比来精确划分训练强度区间？" Checker: 使用"最大摄氧量百分比""生理适应机制"等高度专业术语， 若persona为普通用户则不自然。 → 闭环优化: Prompt 中约束"普通用户使用日常语言，医护人员可使用专业术语"

案例 2 — 类型不匹配:

ID: 170 | persona: 161 | 主题: 运动损伤预防与康复 Query: "帮我看看我过去一个月的每日平均心率和静息心率分别是多少？" Checker: 实际为用户数据查询(Type 2)，标注为知识计算(Type 3) → 闭环优化: Prompt 为三种 Query 类型提供更清晰的边界——Type 2 是"查看数据"，Type 3 是"基于数据做分析/计算/建议"

案例 3 — 逻辑矛盾:

ID: 143 | persona: 98 | 主题: 运动营养与能量补给策略 Query: "帮我看看上个月每次练完之后，手环记录的睡眠平均心率是多少？" Checker: query 内容是睡眠心率，与营养主题无关 → 闭环优化: Prompt 强化"query 核心意图必须与指定 catalog_topic 直接相关"

3.5 审查机制结论

结论	说明
小样本即有效	100 条抽样即清晰定位 3 类主要问题和 1 个高风险主题
问题→优化直接映射	每类问题直接对应 Prompt 的具体修改方向，无需人工分析
任意 Domain 可复现	`_extract_domain_info` 自动提取，同样机制即时应用于任

结论	说明
	意 Domain
闭环持续优化	审查 → Prompt 修改 → 重新生成 → 再审查 → 正常率持续提升
人力成本极低	一次审查数分钟，替代数小时人工逐条检查

4. 谷歌数据场景适配报告

4.1 多维度适配（非机械替换）

维度	审视角度	适配示例	适配逻辑
品牌生态	产品绑定表述	Fitbit → Huawei Watch	确保 query 在华为产品能力范围内自洽
AI 功能命名	竞品 vs 华为 AI 差异	Fitbit LLM → Huawei Assistant	理解两者功能边界差异
专有指标体系	指标定义与计算逻辑	AZM(心率区间) → Intensity Activity Minutes	追溯指标定义后选语义最近概念
评估模型差异	华为生态等价概念	Readiness Score(综合 HRV/睡眠) → Recovery Status	华为使用"恢复时间""跑力指数"
隐含场景语境	LLM 辅助识别	睡眠算法描述 → 华为睡眠监测场景	不是替换品牌名，是重构场景

4.2 适配规模

- 原始: 4,170 条 → 适配后: 7,424 条
- 适配维度: 5 个（品牌/AI 能力/指标/模型/场景）

5. 现网数据抽样报告

指标	值
原始数据池	589,289 条
分类抽样	221 类 × 20 条/类
实际抽样	4,111 条
满额类别	88.7% (196/221)

覆盖：健康管理（睡眠/饮食/环境）、医疗症状（高血压/糖尿病/孕产）、大众运动（跑步/健身/瑜伽）、心理健康（焦虑/抑郁/正念）等。

6. 结论

6.1 综合评价

维度	评价	等级
生态系统完整性	生成 → 审查全链路自动化闭环，checkpoint+重试保障稳定性	优秀
架构可扩展性	5 个 Domain 各有独立 Prompt（含字	优秀

维度	评价	等级
	段目录/指标词典/攻击模板），新Domain 零代码接入	
审查机制有效性	6 维度缺陷分类，小样本即定位问题，直接映射 Prompt 优化方向	优秀
数据合成质量	去重率 0.62%，三维度类型 1:1:1 均衡，101 字段目录硬约束	良好
审查效率	100 条/数分钟，`_extract_domain_info` 自动适配	优秀
场景适配	5 维度生态改写（品牌/AI/指标/模型/场景），非机械替换	良好

6.2 闭环优化路径

基于 Checker 机制已定位的问题，后续 Prompt 迭代方向：

4. **术语层次控制** → SYSTEM_PROMPT 增加"根据 persona 医学知识水平适配术语"约束 → 语言不自然(47.4%)下降
5. **类型边界强化** → 在 Prompt 中为 Type 1/2/3 提供更明确的判别示例 → 类型不匹配(31.6%)下降
6. **主题锚定加强** → 增加"query 核心意图必须与 catalog_topic 直接相关"约束 → 逻辑矛盾(15.8%)下降
7. **各 Domain 全覆盖审查** → 利用同一 Checker 机制对 health/sports/sports_health/red_team 执行审查 → 建立全局质量基线