AI 数据自动化生态系统 — 测试策略与测试设计文档

负责人: 王源田

项目: 健康查询数据自动化生成-审查生态系统

1. 测试背景与目标

1.1 项目概述

围绕已有的健康查询基准数据库 HQB，构建了一套**端到端的 AI 数据自动化生态系统**，覆盖从 Prompt 驱动的数据合成、多源数据清洗与场景适配、UMAP+HDBSCAN 聚类调优，到统一质量审查的全链路。

本系统的核心价值不在于单个模块，而在于**生成 → 聚类 → 审查的一条龙自动化数据管理能力**：

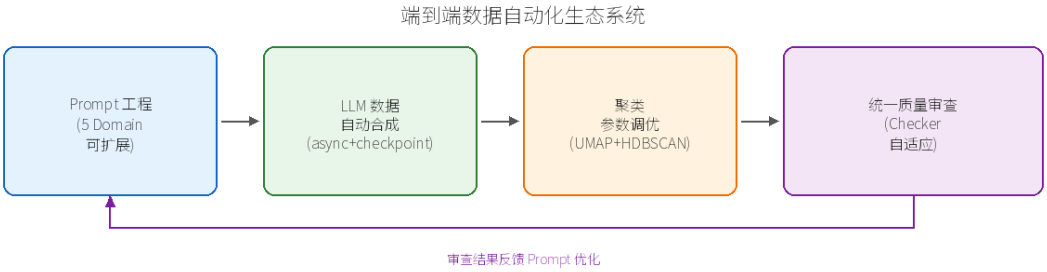

1.2 数据成果总览

数据来源	原始/生成数量	去重/清洗后数量	特性描述
LLM 自动合成	49,200	48,895	结构化强，覆盖通用、显性/隐性个性化维度
谷歌数据场景适配	4,170	7,424	多维度生态改写，适配华为 Watch 场景
现网数据分类抽样	4,111 (抽样)	—	真实性强，捕捉长尾与口语化表达
总计	**57,481**	**56,319**	**多源异构**

1.3 Domain 可插拔架构

每个 Domain 都是独立的数据生成维度，拥有独立的 Prompt 模板文件（`prompts/*.py`），可持续生成且随时扩展新维度：

Domain	独立 Prompt 文件	估计规模	Prompt 核心设计
general_medical	`prompts/general_medical.py`	~500 条	101 个健康数据字段目录硬约束（基础体征/体成分/每日汇总/心率压力/睡眠/健康档案/营养/高频时序）
health	`prompts/health.py`	~500 条	52 个字段 + HEALTH_DATA_MARKDOWN 健康指标词典，支持单域/多域组合（如"心脏健康_睡眠健康"）
sports	`prompts/sports.py`	~500 条	SPORTS_SPECIFIC_INDICATORS 字典覆盖 30+ 运动项目专属指标（如跑步：配速/步频/触地时间/垂直振幅；高尔夫：挥杆速度/推杆数/差点）

Domain	独立 Prompt 文件	估计规模	Prompt 核心设计
sports_health	`prompts/sports_health.py`	~500 条	跨域 persona 适配，融合运动偏好（preferred_sports/sport_mastery/sport_goal）与健康属性
red_team	`prompts/red_team.py`	~500 条	4 类独立攻击模板（prompt_injection / persona_induction / function_inquiry / active_clarification），含攻击难度分级

新 Domain 接入流程（零代码扩展框架）：

```
1. prompts/ 新建 prompt 文件 → 实现 build_persona_block() + build_messages()  2. output_db.py 注册表 DDL → _DOMAIN_TABLE_MAP  3. generator.py 注册 → _DOMAIN_PROMPT_MAP  4. Checker 自动适配 → 无需额外代码 ──────────────────────────────────────────────────────────── 新 Domain 即刻可用，生成 + 审查全链路自动打通
```

1.4 测试目标

目标	说明
生态系统端到端有效性	验证 生成→聚类→审查 全链路自动化运转
架构可扩展性	验证新 Domain 可零代码接入全链路
审查流程效率	验证 Checker 自动化审查对人力的节省效果
LLM 合成数据质量	确保各 Domain 生成 Query 的质量达标
聚类调优效果	验证 9 轮参数调优后噪声率和准确率达标
场景适配完整性	验证谷歌数据多维度改写无遗漏
系统稳定性	验证并发生成、断点续传、失败重试的可靠性

2. 测试范围

2.1 生态系统全链路模块

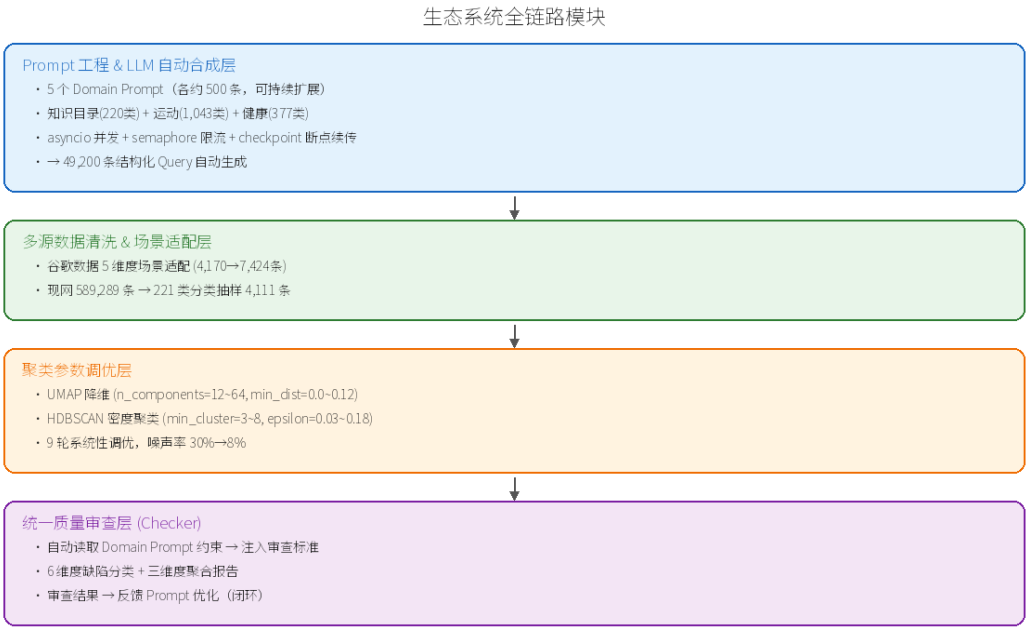

2.2 测试范围矩阵

模块	单元测试	集成测试	数据质量测试	压力测试
5 个 Domain Prompt（build_messages/build_persona_block）	☒	—	☒	—
generator.py（_build_task_list/checkpoint/_dispatch_insert）	—	☒	☒	☒
checker.py（_extract_domain_info/_build_review_prompt）	—	☒	☒	—
output_db.py（init_db/insert_queries/is_generated）	☒	☒	—	—
llm_client.py（chat_json/指数退避重试）	☒	☒	—	☒
聚类参数调优	—	☒	☒	—
谷歌场景适配	—	☒	☒	—

3. 测试策略

3.1 生态系统端到端测试策略

核心测试策略是验证**生成→聚类→审查**的一条龙闭环：

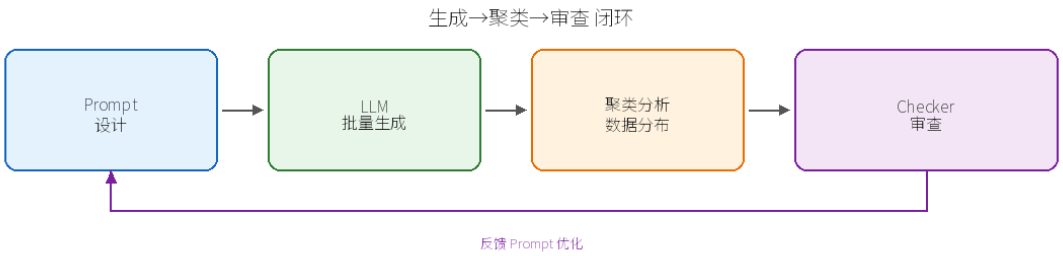

3.2 LLM 数据合成质量测试策略

全量生成规则：**1 个类别 30 条 Query（10 通用 + 10 显性个性化 + 10 隐性个性化）**

阶段一：Prompt 约束内嵌

每个 Domain 的 Prompt 文件中，通过 `build_messages()` 函数构造 system + user 消息对，在 SYSTEM_PROMPT 中内嵌以下约束：

- **三类型结构约束**: Type 1 = 通用知识查询（不涉及个人数据）；Type 2 = 显性个性化（直接请求 1-3 个数据字段）；Type 3 = 隐性个性化（隐含需要 2-4 个数据字段做分析计算）
- **字段合规约束**: 在 general_medical 中维护 101 个字段的 DATA_FIELD_CATALOG（基础信息/体成分/每日汇总/心率压力/睡眠/健康档案/营养/高频时序 8 大类），health 维护 52 个字段
- **人设一致性约束**: `build_persona_block()` 将 persona 的年龄/性别/BMI/健康关注/运动偏好等结构化渲染为 LLM 可读的卡片
- **术语适配约束**: Prompt 要求 LLM 根据 persona 的医学知识水平调整术语——普通用户用日常语言，医疗专业人员可用专业术语

阶段二：Checker 自动审查

Checker（`checker.py`）是本生态系统的**质量闭环引擎**：

1. `_extract_domain_info(domain)` 自动从对应 Domain 的 prompt 模块中提取 SYSTEM_PROMPT 和 query_type 定义
2. `_build_review_prompt()` 将提取的生成约束注入审查 prompt，让 LLM reviewer 理解原始质量标准
3. 分批审查（默认 batch_size=30），temperature=0.3 低方差模式
4. 6 维度缺陷分类：语言不自然 / 类型不匹配 / 逻辑矛盾 / 格式违规 / 重复 / 质量低下
5. `_write_report()` 输出按 Query 类型 / 知识主题 / 问题类型三维聚合的结构化报告

关键架构优势: 新增 Domain 只要在 `_DOMAIN_PROMPT_MAP` 中注册了 prompt 模块，Checker 就能自动审查，无需额外代码。

阶段三：聚类验证

对数据进行 UMAP+HDBSCAN 聚类后，通过 LLM 逐簇验证主题一致性，作为第二重质量保障。

3.3 聚类参数调优策略

本人负责聚类参数的系统性调优，共执行 **9 轮实验**，探索 UMAP（n_neighbors / n_components / min_dist）和 HDBSCAN（min_cluster_size / min_samples / epsilon / method）共 6+ 个参数维度：

版本	n_comp	min_dist	min_clust	min_samp	eps	簇数	噪声率
初始	64	0.0	5	3	0.03	2,054	~30%
方案 A	64	0.05	3	1	0.06	3,595	~16%
v1	**64**	**0.0**	**3**	**1**	**0.08**	**1,899**	**~8%**
v2	12	0.12	3	1	0.18	883	~5%
v3	**12**	**0.0**	**3**	**1**	**0.08**	**1,823**	**~8%**

参数影响规律:

参数	降低 →	增加 →
epsilon	更多噪声（HDBSCAN 对密度要求更严格）	更少噪声（允许更松散的点归入簇）
min_samples	更少噪声（核心点判定更宽松）	更多噪声（核心点判定更严格）
min_cluster_size	更少噪声（允许更小的簇）	更多噪声（小簇被判定为噪声）
min_dist (UMAP)	嵌入点更聚集，簇边界模糊	嵌入点更分散，簇边界更清晰
n_components (UMAP)	更少簇（粗粒度，但大簇多）	更多簇（细粒度，信息保留多）

3.4 谷歌数据多维度场景适配策略

改写**不是机械的关键词替换**，而是从 5 个维度审视竞品生态语境后的语义等价适配：

维度	审视角度	适配示例
品牌生态绑定	识别与 Google/Fitbit 产品绑定的表述	Fitbit → Huawei Watch
AI 功能命名	竞品 AI 功能 vs 华为对应功能的差异	Fitbit LLM → Huawei Assistant
专有指标体系	分析竞品独有指标的定义与计算逻辑	Active Zone Minutes (基于心率区间) → Intensity Activity Minutes
健康评估模型	理解竞品评估模型含义，找等价概念	Readiness Score (综合 HRV/睡眠/活动) → Recovery Status
隐含场景语境	LLM 辅助识别非直接命名的竞品关联	"Fitbit 追踪睡眠的算法" → 华为 Watch 睡眠监测场景

3.5 系统可靠性测试策略

系统可靠性基于 `llm_client.py` 的指数退避和 `generator.py` 的 checkpoint 机制：

测试场景	实现机制	预期结果
并发稳定性（--batch 10）	asyncio.Semaphore 限流 + asyncio.Lock 保护 DB 写入	无死锁、无数据竞争
断点续传	`is_generated()`/`is_topic_generated()` 检查 persona×topic 是否已有数据	跳过已完成任务
指数退避重试	`delay = min(2 × 2^(retry-1), 30)` 秒，默认最大重试 100 次	API 限流下自动恢复
失败记录	`_record_failure()` → failed_tasks 表 (domain/persona/topic/error/attempts/timestamp)	异常完整可溯

4. 测试设计

4.1 端到端全链路测试用例

用例 ID	测试点	验证方法	通过标准
E2E-001	生成→审查闭环	对任一 Domain 生成后立即 Checker 审查	报告自动生成，含三维聚合
E2E-002	新 Domain 接入	新建 prompt + 注册后运行 generator + checker	零额外代码全链路打通
E2E-003	审查→优化闭环	Checker 发现问题后修改 Prompt 重新生成	正常率提升
E2E-004	聚类→审查交叉验证	对同一数据集分别用聚类和 Checker 验证	两种方法发现的问题互补

4.2 各 Domain Prompt 生成测试用例

用例 ID	Domain	测试重点	验证方法
DP-001	general_medical	101 个字段目录硬约束 + build_persona_block 人设渲染	生成 ~500 条，检查 data_fields 合规率
DP-002	health	52 个字段 + topic_count 多子域主题（如"心脏_睡眠"）	验证多子域 query 的跨域融合质量
DP-003	sports	REQUIRES_PERSONA=False，LLM 内联生成 15 个多样化 persona	验证 persona 多样性（性别/年龄/运动/水平分布）
DP-004	sports_health	跨域 persona（preferred_sports + core_health_concerns）	验证运动×健康交叉场景的合理性
DP-005	red_team	4 类攻击模板（injection/induction/inquiry/clarification）	验证攻击类型覆盖 + 难度分级
DP-006	新 Domain	新建 prompt 文件 → 实现 build_messages()	零代码接入全链路

4.3 批量生成数据完整性用例

用例 ID	测试点	验证方法
DI-001	知识目录	220 类 × 30 条 = 6,600
DI-002	运动板块	160 单项 + 883 跨项组合 = 1,043 × 30 = 31,290

用例 ID	测试点	验证方法
DI-003	健康板块	C(13,1)+C(13,2)+C(13,3) = 377 × 30 = 11,310
DI-004	类型均衡	通用:显性:隐性 = 10:10:10 严格均衡
DI-005	去重效果	49,200 → 48,895（去重率 0.62%）
DI-006	DB 完整性	queries 表 JSON 字段（data_fields/persona_sports/persona_goals）可正常解析

4.4 输出数据库 Schema 验证用例

系统使用 SQLite（WAL 模式 + 外键约束），output_db.py 管理 6 张表：

用例 ID	表名	验证重点
DB-001	personas	20 个字段完整性，JSON 数组字段（personality_tags/preferred_sports/core_health_concerns）可解析
DB-002	queries_general_medical	persona_id 外键有效，group_index 覆盖 1~n，query_type 值域 1/2/3
DB-003	queries_health	同上 + topic_count 字段正确反映子域数量
DB-004	queries_sports	catalog_topic 索引有效，内联 persona 字段（gender/age/bmi/sports/level）非空
DB-005	queries_red_team	query_category 值域覆盖 4 类攻击，extra_fields JSON 结构与对应攻击类型匹配
DB-006	failed_tasks	失败任务完整记录 domain/persona_id/topic/error/attempts/timestamp

4.5 Checker 审查流程测试用例

用例 ID	测试点	通过标准
CK-001	`_extract_domain_info` 自动适配任意 Domain	正确提取 SYSTEM_PROMPT + has_persona
CK-002	`_build_review_prompt` 自动注入生成约束	审查 prompt 包含原始类型定义和字段目录
CK-003	抽样审查效率	100 条/数分钟 → 定位主要问题类型
CK-004	报告三维聚合	按 Query 类型 / 知识主题 / 问题类型 三个维度自动统计
CK-005	6 维度缺陷检测	覆盖语言不自然/类型不匹配/逻辑矛盾/格式违规/重复/质量低下

5. 测试环境

环境项	配置
OS	Linux / Windows
Python	3.10+ (via uv)
数据库	SQLite 3.x (WAL 模式, 外键约束)
LLM API	deepseek-v3.2 (OpenAI-compatible endpoint)，temperature=0.8/0.3

环境项	配置
并发框架	asyncio + Semaphore + Lock
聚类工具	UMAP + HDBSCAN (hqb cluster CLI)
HTTP 客户端	httpx (timeout=120s, proxy 支持)

6. 风险与缓解

风险	实现层缓解机制	测试层验证
LLM 输出不稳定	Checker 自动审查 (temp=0.3) + Prompt 约束	抽样审查正常率 ≥ 80%
API 限流/超时	`delay = min(2×2^(n-1), 30)` 指数退避 + checkpoint	断点续传测试
数据字段幻觉	DATA_FIELD_CATALOG 硬约束 (101/52 字段)	Checker 格式违规检测
聚类大簇	参数调优(v1/v3) + 二次聚类	噪声率 < 10%
新 Domain 质量不稳	Checker `_extract_domain_info` 自适应	首轮抽样即定位问题
DB 写入竞争	asyncio.Lock 保护 + SQLite WAL	并发写入无重复